



DeepNASDAQ - Predictor

Girica Cristiana-Maria

Miron Alin-Andrei

Nanciu-Alexandru David-Ioan

Nitu Tudor-Andrei

Nitu Andrei-Raul

CAPITOLUL 1: INTRODUCERE ȘI MOTIVAȚIA ECONOMICĂ A PROIECTULUI

Am ales să facem proiectul pentru companiile aeriene din indexul NASDAQ pe o perioadă de 25 de ani (2001 - 2026). Companiile aeriene sunt perfecte pentru un experiment la rețele neuronale pentru că sunt ultra-sensibile la crize precum atacurile din 2001, criza din 2008, perioada din 2020 când nu a mai zburat nimeni din cauza pandemiei și, mai recent problemele cu prețul combustibilului.

1.2 Eșantionul experimentului

Am curățat datele și am păstrat 5 companii aeriene mari:

1. **AAL (American Airlines):** O companie clasică, uriașă, cu zboruri peste tot în lume. Are costuri fixe foarte mari (avioane mari, aeroporturi scumpe).
2. **UAL (United Airlines):** Alt jucător imens internațional.
3. **JBLU (JetBlue Airways):** O companie de nivel mediu, axată mai mult pe zboruri interne în SUA, cu servicii un pic mai bune, dar prețuri accesibile.
4. **SNCY (Sun Country Airlines):** O companie modernă ultra-low-cost (foarte ieftină) care face și zboruri charter și transportă marfă.
5. **RJET (Republic Airways):** O companie regională mică. Ei nu vând neapărat bilete direct la oameni, ci închiriază avioanele cu tot cu echipaj companiilor mari. Au o logică financiară total diferită.

1.3 Miza proiectului: Criza Kerosenului

Combustibilul (kerosenul) reprezintă între 25% și 40% din toate cheltuielile unei companii aeriene. Când prețul petrolului explodează, profitul lor se prăbușește instant, pentru că nu pot scumpi biletele de azi pe mâine fără să piardă clienți.

Miza inovatoare a proiectului nostru este să vedem dacă rețelele neuronale se prind de aceste șocuri. Vrem să vedem dacă modelele noastre pot detecta când se strică trendul acțiunilor din cauza prețului la kerosen și dacă giganții (gen AAL) suferă mai mult decât companiile mai mici și flexibile (gen SNCY).

1.4 Ce vrem să prezicem?

Facem o sarcină de regresie (adică prezicem un număr continuu — prețul de încidere acțiunii, nu doar dacă crește sau scade). Ne uităm la o fereastră de 30 de zile din trecut (LOOKBACK = 30) și încercăm să ghicim prețul pentru ziua următoare (TARGET).

CAPITOLUL 2: INGINERIA CARACTERISTICILOR

2.1 Adunarea fișierelor împrăștiate

Primul nostru script (preprocesare.py) a scanat toate folderele împartite pe zile ale setului de date NASDAQ, a ales simbolurile companiilor care nu ne interesau (AAL, UAL, JBLU, SNCY, RJET) și a lipit într-un singur fișier mare doar datele pentru cele 5 companii aeriene ale noastre, sortate de la anul 2001 până în 2026.

2.2 Calcularea indicatorilor tehnici (Features)

Dacă îi dăm rețelei doar prețul brut, nu o ajutam prea mult. De aceea, am creat pe baza prețului de închidere (Close) mai multe variabile ajutătoare (indicatori tehnici pe care îi folosesc și traderii la bursă):

Ce înseamnă fiecare variabilă calculată:

1. **Open, High, Low, Close:** Prețurile din ziua respectivă (la deschidere, cel mai mare, cel mai mic și cel de la închiderea ședinței bursiere).
2. **Volume:** Câte acțiuni s-au vândut/cumpărat în acea zi. Dacă prețul scade și volumul e uriaș, e semn clar de panică în piață.
3. **Return:** Randamentul zilnic (cu cât la sută a crescut sau a scăzut prețul azi față de ieri).
4. **SMA_5, SMA_20, SMA_50:** Medii mobile simple (pe o săptămână, o lună, respectiv două luni). Practic, netezesc linia prețului ca să vedem trendul clar, fără hopurile zilnice.
5. **EMA_12, EMA_26:** Medii mobile exponențiale. Sunt similare cu SMA, dar sunt mai "deștepte" pentru că dau o importanță mai mare zilelor foarte recente.
6. **MACD:** Se calculează scăzând EMA_26 din EMA_12. Ne arată dacă trendul curent are viteză (momentum) sau dacă se stinge.
7. **BB_UPPER / BB_LOWER (Benzi Bollinger):** Două linii în jurul prețului. Când benzile se depărtează brusc, înseamnă că piața a devenit extrem de agitată (volatilitate mare).
8. **VOLATILITY:** Este deviația standard a randamentelor pe ultimele 20 de zile. Este variabila cheie pentru risc; ne arată matematic cât de panicată este piața.
9. **TARGET:** Este prețul Close din ziua următoare (luat cu funcția $\text{shift}(-1)$). Pe acesta încercăm să îl prezicem.

2.3 Pasul 2: Împărțirea și scalarea datelor

Aici trebuie să fim foarte atenți la o regulă: nu amestecăm datele la întâmplare (fără K-Fold clasic!). Dacă amestecăm zilele aleatoriu, rețeaua ar vedea date din viitor când încearcă să învețe trecutul, ceea ce se numește *Data Leakage*. De aceea, am făcut un Split Cronologic: am luat primele 80% din zile din trecut pentru antrenare (Train) și am lăsat ultimele 20% (perioada cea mai recentă) pentru testare (Test).

În plus, pentru că rețelele neuronale se încurcă atunci când primesc numere uriașe (cum sunt volumele de milioane de acțiuni) amestecate cu numere mici (cum e volatilitatea), am aplicat MinMaxScaler. Această funcție strânge toate valorile pe o scară uniformă, strict între 0 și 1.

CAPITOLUL 3: MOTORUL DE ANTRENARE

Am creat o clasă custom numită ModelTrainer.

3.1 Banda de gradienti (tf.GradientTape) și cum învață rețeaua

În metoda `train_step`, folosim un concept numit `tf.GradientTape`. Când datele trec prin rețea, banda înregistrează operațiile și calculează eroarea (Loss-ul, adică diferența dintre prețul real și cel ghicit).

Imediat după, dăm derularea înapoi prin algoritmul de *Backpropagation* (`tape.gradient`). Acest pas calculează derivatele matematice, adică ne spune exact care ponderi (legături) din rețea au greșit și cu cât. Apoi, optimizatorul (Adam) vine și ajustează acele ponderi ca data viitoare rețeaua să greșească mai puțin.

3.2 Early Stopping

Clasa `ModelTrainer` folosește două mecanisme la fiecare epocă:

- **Salvarea automată (Checkpoint):** Trimitem modelul pe datele de validare (`val_step`). Dacă eroarea curentă este mai mică decât cea precedentă, modelul își salvează imediat ponderile optime pe disc.
- **Oprirea din timp (Early Stopping):** Dacă eroarea pe datele de validare nu mai scade timp de 10 epoci consecutive (`patience=10`), antrenarea este oprită automat). Astfel, economisim timp și resurse de calcul, evitând epocile inutile în care rețeaua doar ar stagna sau s-ar degrada.

La final, prin funcția `restore_best_weights()`, reîncărcăm automat exact versiunea ideală salvată înainte ca modelul să înceapă să stagneze.

CAPITOLUL 4: CELE 3 MODELE

Am implementat și testat trei tipuri diferite de arhitecturi de rețele ca să vedem care se descurcă mai bine pe acțiunile companiilor aeriene:

4.1 Modelul 1: LSTM Simplu

Rețelele neuronale simple nu au memorie; ele analizează fiecare zi separat și uită ce s-a întâmplat ieri. Rețelele LSTM (Long Short-Term Memory) sunt revoluționare pentru că au niște porți care controlează fluxul de informație:

- **Poarta de uitare (Forget Gate):** Decide dacă informațiile vechi din istoric mai sunt utile sau trebuie șterse.
- **Poarta de intrare (Input Gate):** Filtrează informațiile din ziua curentă și le adaugă în celula de memorie.
- **Poarta de ieșire (Output Gate):** Decide ce informație stocată merge mai departe către stratul următor.

Configurația și parametrii aleși:

Am pus un prim strat LSTM mare de 128 de unități (neuroni) care colectează toți indicatorii noștri tehnici pe o lungime de 30 de zile (input_shape). Am activat return_sequences=True ca să transmitem structura 3D intactă următorului strat LSTM, care are 64 de unități. Am adăugat straturi de Dropout(0.2) ca frână împotriva memorării pe de rost a zgomotului din date, iar la final un strat liniar Dense(1) scoate prețul final estimat. Optimizatorul folosit este Adam cu o rată mică și sigură de învățare (learning_rate=0.0005).

4.2 Modelul 2: BiLSTM (LSTM Bidirecțional)

Un LSTM clasic citește datele normal: de la trecut spre viitor (de la stânga la dreapta). Modelul BiLSTM (Bidirectional LSTM) dublează această putere: el antrenează două straturi LSTM în paralel. Unul parcurge datele în sens normal cronologic, iar celălalt le citește în sens invers (de la prezent înapoi în trecut).

La final, rezultatele lor se unesc. Economice vorbind, asta îi dă rețelei un plus de context: corelează șocurile din piață cu acumulările istorice din ambele perspective, fiind teoretic mult mai bună la detectarea anomaliilor de preț.

4.3 Modelul 3: CNN-LSTM (Modelul Hibrid)

Aceasta combina straturile Convoluționale 1D (Conv1D) — luate din zona de procesare de imagini — cu straturile de memorie LSTM:

1. **Partea de CNN (Filtrarea):** Aplicăm 64 de filtre care scanează fereastra noastră. Ele caută tipare geometrice rapide (gen forme specifice lăsate pe grafic de Benzile Bollinger sau intersecții de MACD pe o perioadă scurtă de 3 zile). Stratul MaxPooling1D comprimă rezultatele și aruncă zgomotul minor din piață.
2. **Partea de LSTM (Memoria):** Datele curate și filtrate de CNN sunt trimise către blocurile LSTM, care analizează cum evoluează aceste tipare pe termen mai lung.

CAPITOLUL 5: REZULTATELE GENERATE ȘI INTERPRETAREA LOR (SETUL DE TEST)

5.1 Cum măsurăm performanța? (Erori în Dolari Reali)

Ca proiectul să aibă sens economic, am folosit funcția inverse_transform a scalerului. Asta înseamnă că nu calculăm erorile pe numere ciudate între 0 și 1, ci transformăm rezultatele înapoi în Dolari (USD). Evaluăm modelele după trei metrici:

- **MAE (Mean Absolute Error):** Eroarea medie absolută. Îți spune în medie cu câți dolari trece modelul pe lângă prețul real.
- **RMSE (Root Mean Squared Error):** Penalizează mult mai dur greșelile mari (zilele în care modelul a dat total pe lângă).

- **R² (Coeficientul de Determinare):** Ne arată în procente cât din mișcarea reală a acțiunilor a fost înțeleasă de model (cu cât e mai aproape de 1.0 sau 100%, cu atât mai bine).

5.2 Ce ne-a afișat consola după rularea testelor:

După rularea scriptului de evaluare comparative, am obținut următoarele rezultate:

===== Evaluare Model: LSTM =====

Global Real -> MAE: 2.25 USD | RMSE: 3.36 USD | R2: 0.98123

===== Evaluare Model: BiLSTM =====

Global Real -> MAE: 3.13 USD | RMSE: 3.97 USD | R2: 0.97370


===== Evaluare Model: CNN_LSTM =====


Global Real -> MAE: 2.34 USD | RMSE: 3.92 USD | R2: 0.97441

Ce model a câștigat?

1. *Locul 1: LSTM Simplu (R² = 0.98123 | MAE = 2.25 USD)*

- **Verdict:** Este cel mai bun model. O acuratețe de peste 98% arată că rețeaua a înțeles perfect trendul.
- **Explicație:** În finanțe, cauzalitatea clasică (trecutul imediat determină viitorul apropiat) oferă cel mai curat semnal, modelul greșind în medie cu doar 2.25 dolari.











2. Locul 2: CNN-LSTM ($R^2 = 0.97441$ | $MAE = 2.34$ USD)


- **Verdict:** Performanță foarte aproape de primul loc.
- **Explicație:** Straturile convoluționale (Conv1D) ajută modelul să filtreze zgomotul și să extragă corect formele geometrice (tiparele) din indicatorii tehnici înainte de procesarea temporală.


Training vs Validation Loss



3. Locul 3: BiLSTM ($R^2 = 0.97370$ | $MAE = 3.13$ USD)

- **Verdict:** Cel mai slab model din cele trei (deși rezultatul de 97% rămâne unul ridicat).
- **Explicație:** Forțarea rețelei să citească timpul și invers (de la prezent spre trecut) introduce zgomot inutil. În bursă, fluxul invers distorsionează logica economică, mărin eroarea cu aproape un dolar față de modelul simplu.





CAPITOLUL 6: PROGNOZA ÎN VIITOR PE 252 DE ZILE (AUTOREGRESIVĂ)

6.1 Cum pășim în viitor fără date reale?

Pentru că nu avem date reale din viitor, am configurat o simulare în buclă închisă (recursive forecasting):

- În prima zi de prognoză, rețeaua primește ultimele 30 de zile reale și prezice prețul pentru „mâine”.
- Noi luăm acest preț inventat (prezis) și îl lipim la sfârșitul tabelului nostru ca și cum ar fi o zi reală.
- În a doua zi de prognoză, rețeaua citește o nouă fereastră de 30 de zile, dar acum aceasta conține 29 de zile reale și 1 zi prezisă chiar de ea la pasul trecut. Până ajungem la ziua 50 sau 200, rețeaua prezice viitorul bazându-se exclusiv pe propriile ei predicții din pașii anteriori.

6.2 Recalcularea automată din mers a indicatorilor

O rețea complexă s-ar fi blocat imediat dacă îi dădeam doar prețul Close modificat, pentru că ea știe că la intrare trebuie să primească 9 variabile complete.


Codul nostru rezolvă această problemă prin inginerie dinamică a caracteristicilor: în interiorul buclei, pentru fiecare zi nouă prezisă, programul simulează instantaneu și restul variabilelor din mers:

- Calculează un High și un Low artificial, adăugând/scăzând o marjă mică de 0.5%.
- Recalculează mediile mobile SMA_5 și SMA_20 integrând prețurile proaspăt prezise.
- Actualizează dinamic indicatorul de momentum MACD și cel de risc VOLATILITY.

6.3 Riscul acumulării de erori (Error Propagation)

Graficele noastre pe un an în viitor vor arăta ca niște curbe organice și fluide de evoluție economică. Totuși, trebuie menționat un risc matematic major numit Efectul de cascadă al erorilor: dacă modelul greșește fie și cu 10 cenți în prima săptămână, acei 10 cenți intră în calculul mediilor mobile din săptămâna a doua, deformând intrările și forțând modelul să

greșească și mai mult în săptămâna a treia. Eroarea se amplifică ca un bulgăre de zăpadă spre finalul celor 252 de zile.



1. AAL (American Airlines)

- **Comportament pe grafic:** Prețul pleacă de jos (de la aproximativ 13 USD) și are o creștere explozivă în primele 100 de zile, după care se plafonează (devine o linie dreaptă, plată) în jurul valorii de 30 USD până la finalul anului.
- **Explicație economică:** Modelul a detectat că AAL este un gigant tradițional care își revine puternic după un șoc de volatilitate. Totuși, din cauza acumulării progresive de erori în bucla închisă și a costurilor fixe mari ale companiei, modelul își pierde dinamică și intră într-o fază de echilibru artificial (stagnare statistică la 30 USD).

2. JBLU (JetBlue Airways)

- **Comportament pe grafic:** O traiectorie curată în formă de "S". Pleacă de la un preț minim de 6 USD, crește constant și uniform în primele 150 de zile, iar spre final se stabilizează foarte frumos la puțin peste 16 USD.
- **Explicație economică:** Fiind un operator hibrid axat pe piața internă, modelul prognozează o recuperare stabilă și mai puțin agresivă decât în cazul AAL. Graficul arată o evoluție organică și realistă a pieței, semn că indicatorii tehnici recalculați din mers (ca SMA și MACD) au menținut modelul pe un trend logic.

3. RJET (Republic Airways)

- **Comportament pe grafic:** În primele 10-15 zile, prețul scade ușor (de la 19.4 USD la un minim de 18.5 USD), după care își revine spectaculos și se plafonează complet la valoarea fixă de 23.4 USD.
- **Explicație economică:** Această scădere inițială urmată de o revenire rapidă arată că rețeaua a captat perfect sensibilitatea pe termen scurt a aviației regionale la șocul kerosenului. Stabilizarea timpurie la o linie perfect dreaptă reflectă fidel modelul lor de business: contracte pe termen lung cu sume fixe per oră de zbor, ceea ce elimină variațiile haotice de preț.

4. SNCY (Sun Country Airlines)

- **Comportament pe grafic:** Similar cu RJET, vedem o corecție vizibilă în primele 15 zile (prețul scade de la 16.5 USD la 14.2 USD), urmată de o creștere lungă și stabilă, care se plafonează spre ziua 160 la pragul de 25 USD.
- **Explicație economică:** Modelul a simulat realitatea: un operator ultra-low-cost încasează un șoc puternic la început din cauza scumpirii combustibilului, dar flexibilitatea flotei și divizia lor de cargo le permit să își recupereze valoarea pe bursă în a doua jumătate a anului.

5. UAL (United Airlines)

- **Comportament pe grafic:** O traiectorie total diferită — o prăbușire exponențială continuă în primele 100 de zile, de la un preț uriaș de peste 90 USD, până când atinge un prag de suport la 58.8 USD, unde rămâne blocat până la final.
- **Explicație economică:** UAL este un pilon major internațional. Modelul a interpretat că, în contextul crizei și al volatilității, acțiunile UAL erau masiv supraevaluate la peste 90 USD. Rețeaua forțează o corecție dură de piață până când prețul atinge valoarea considerată "corectă" de către model (aproximativ 59 USD).

CAPITOLUL 7: CONCLUZII

Proiectul nostru a demonstrat cu succes că modelele de Deep Learning pot fi folosite pentru a internaliza riscul și volatilitatea din sectorul aviatic NASDAQ. Modelele au învățat să

reaționeze la indicatorii de panică, iar rețeaua LSTM Simplu a ieșit învingătoare, oferind o eroare medie extrem de mică (2.25 USD) și un control stabil pe trend.